

```
# 21BRS1617
# Sukanth K
```

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
```

```
# Loading the dataset
```

```
df=pd.read_csv('/content/winequality-red.csv')
df
```

	fixed acidity	volatile acidity	citric acid	residual sugar
chlorides \				
0	7.4	0.700	0.00	1.9
0.076				
1	7.8	0.880	0.00	2.6
0.098				
2	7.8	0.760	0.04	2.3
0.092				
3	11.2	0.280	0.56	1.9
0.075				
4	7.4	0.700	0.00	1.9
0.076				
...
...				
1594	6.2	0.600	0.08	2.0
0.090				
1595	5.9	0.550	0.10	2.2
0.062				
1596	6.3	0.510	0.13	2.3
0.076				
1597	5.9	0.645	0.12	2.0
0.075				
1598	6.0	0.310	0.47	3.6
0.067				

	free sulfur dioxide	total sulfur dioxide	density	pH
sulphates \				
0	11.0	34.0	0.99780	3.51
0.56				
1	25.0	67.0	0.99680	3.20
0.68				
2	15.0	54.0	0.99700	3.26
0.65				
3	17.0	60.0	0.99800	3.16
0.58				
4	11.0	34.0	0.99780	3.51
0.56				

```

...
...
...
1594          32.0          44.0  0.99490  3.45
0.58
1595          39.0          51.0  0.99512  3.52
0.76
1596          29.0          40.0  0.99574  3.42
0.75
1597          32.0          44.0  0.99547  3.57
0.71
1598          18.0          42.0  0.99549  3.39
0.66

```

```

      alcohol  quality
0         9.4        5
1         9.8        5
2         9.8        5
3         9.8        6
4         9.4        5
...
1594      10.5        5
1595      11.2        6
1596      11.0        6
1597      10.2        5
1598      11.0        6

```

```
[1599 rows x 12 columns]
```

```
df.shape
```

```
# Data Preprocessing and Visualisation
```

```
# Null Values
```

```
df.isnull().sum()
```

```

fixed acidity      0
volatile acidity   0
citric acid        0
residual sugar     0
chlorides          0
free sulfur dioxide 0
total sulfur dioxide 0
density           0
pH               0
sulphates         0
alcohol           0
quality           0
dtype: int64

```

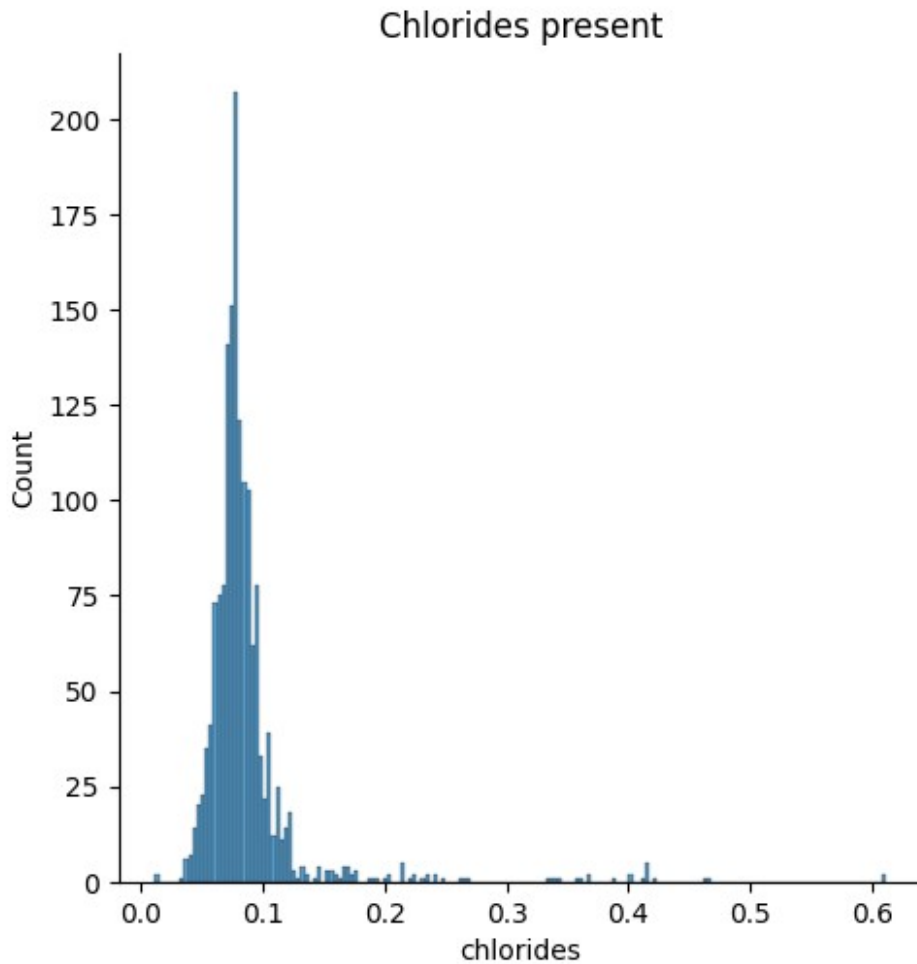
```
df.isnull().any()
```

```
fixed acidity      False
volatile acidity   False
citric acid        False
residual sugar     False
chlorides          False
free sulfur dioxide False
total sulfur dioxide False
density           False
pH                False
sulphates         False
alcohol           False
quality           False
dtype: bool
```

```
# Data Visualisation
```

```
# Univariate
```

```
sns.displot(df['chlorides'])
plt.title('Chlorides present')
plt.show()
```



```
sns.distplot(df['pH'])  
plt.title('pH')  
plt.show()
```


<ipython-input-9-7af5d83ca87c>:1: UserWarning:

`distplot` is a deprecated function and will be removed in seaborn v0.14.0.

Please adapt your code to use either `displot` (a figure-level function with similar flexibility) or `histplot` (an axes-level function for histograms).


For a guide to updating your code to use the new functions, please see <https://gist.github.com/mwaskom/de44147ed2974457ad6372750bbe5751>

```
sns.distplot(df['pH'])
```




```
sns.boxplot(df['density'])
```

<Axes: >

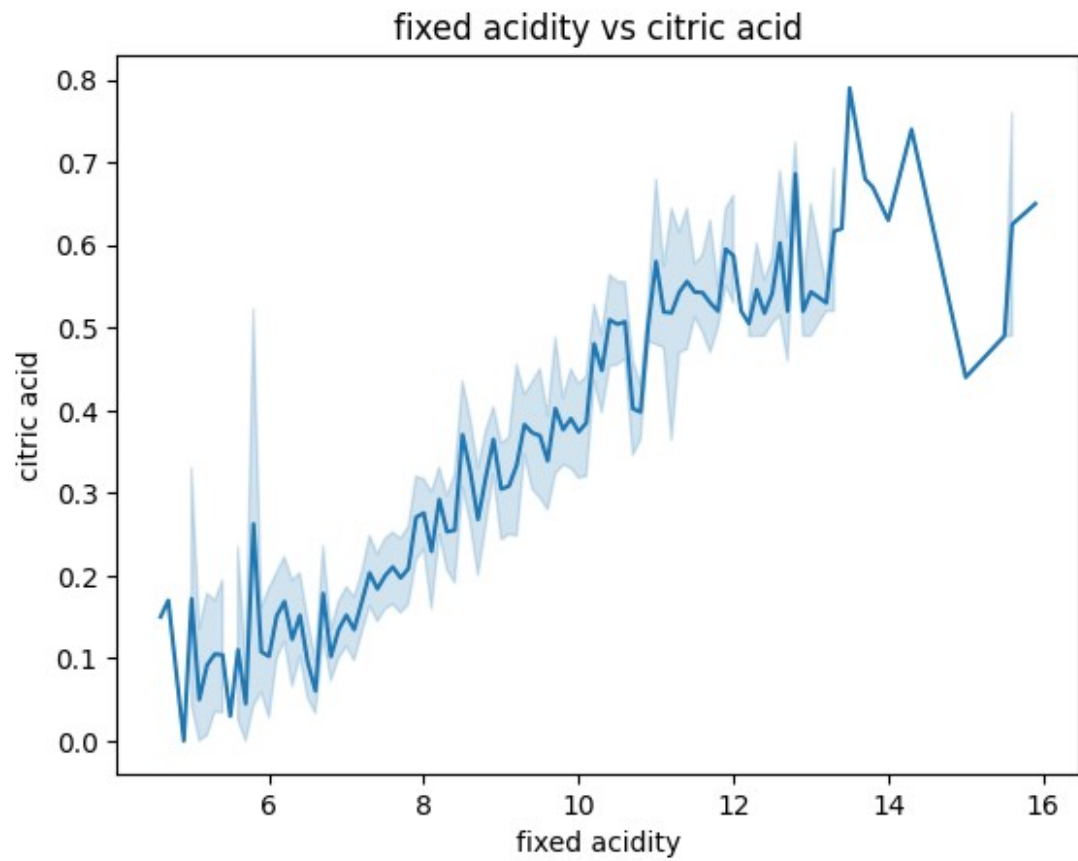


```
# Bivariate
```


```
plt.figure(figsize=(20,20))  
sns.barplot(x=df['chlorides'],y=df['density'])  
plt.title('chlorides vs density')  
plt.show()
```



```
sns.lineplot(x=df['fixed acidity'],y=df['citric acid'])  
plt.title('fixed acidity vs citric acid')  
plt.show()
```




```
sns.scatterplot(x=df['quality'],y=df['residual sugar'])  
plt.title('residual sugar vs quality')  
plt.show()
```

```
# Multivariate
```

```
plt.figure(figsize=(12,12))  
sns.heatmap(df.corr(),annot=True)
```

```
<Axes: >
```



Correlation with respect to target

```
df.corr().quality.sort_values(ascending=False)
```

```
quality          1.000000
alcohol          0.476166
sulphates        0.251397
citric acid      0.226373
fixed acidity    0.124052
residual sugar   0.013732
free sulfur dioxide -0.050656
```

```

pH                -0.057731
chlorides          -0.128907
density           -0.174919
total sulfur dioxide -0.185100
volatile acidity   -0.390558
Name: quality, dtype: float64


```

```

# Check for outliers
plt.figure(figsize=(20,20))
sns.boxplot(df)

```

<Axes: >



```

q1=df.alcohol.quantile(0.25)
q3=df.alcohol.quantile(0.75)

IQR=q3-q1
IQR

1.5999999999999996

ul=q3+1.5*IQR
ul

13.5

ll=q1-1.5*IQR
ll

7.1000000000000005


df.alcohol.median()

10.2

df['alcohol']=np.where(df['alcohol']>ul,df.alcohol.median(),df['alcohol'])
sns.boxplot(df['alcohol'])


<Axes: >

```



```
sns.boxplot(df['chlorides'])
```

<Axes: >



```
q1=df.chlorides.quantile(0.25)
```

```
q3=df.chlorides.quantile(0.75)
```

```
IQR=q3-q1
```

```
IQR
```

```
0.019999999999999999
```

```
ul=q3+1.5*IQR
```


```
ll=q1-1.5*IQR
```

```
df.chlorides=np.where(df.chlorides>ul,df.chlorides.median(),df.chlorides)
```

```
df.chlorides=np.where(df.chlorides<ll,df.chlorides.median(),df.chlorides)
```

```
sns.boxplot(df['chlorides'])
```

<Axes: >



```

q1=df['total sulfur dioxide'].quantile(0.25)
q3=df['total sulfur dioxide'].quantile(0.75)
IQR=q3-q1
IQR

40.0

ul=q3+1.5*IQR
ll=q1-1.5*IQR
df['total sulfur dioxide']=np.where(df['total sulfur
dioxide']>ul,df['total sulfur dioxide'].median(),df['total sulfur
dioxide'])

q1=df['free sulfur dioxide'].quantile(0.25)
q3=df['free sulfur dioxide'].quantile(0.75)
IQR=q3-q1
IQR


14.0

ul=q3+1.5*IQR
ll=q1-1.5*IQR
df['free sulfur dioxide']=np.where(df['free sulfur
dioxide']>ul,df['free sulfur dioxide'].median(),df['free sulfur
dioxide'])

```

```
sns.boxplot(df['free sulfur dioxide'])
```

<Axes: >



```
q1=df['fixed acidity'].quantile(0.25)
```

```
q3=df['fixed acidity'].quantile(0.75)
```

```
IQR=q3-q1
```

```
IQR
```

```
2.0999999999999996
```


```
ul=q3+1.5*IQR
```

```
ll=q1-1.5*IQR
```


```
df['fixed acidity']=np.where(df['fixed acidity']>ul,df['fixed acidity'].median(),df['fixed acidity'])
```

```
sns.boxplot(df['fixed acidity'])
```

<Axes: >



```
q1=df['volatile acidity'].quantile(0.25)
q3=df['volatile acidity'].quantile(0.75)
IQR=q3-q1
IQR
0.25
ul=q3+1.5*IQR
ll=q1-1.5*IQR
df['volatile acidity']=np.where(df['volatile acidity']>ul,df['volatile
acidty'].median(),df['volatile acidity'])
sns.boxplot(df['volatile acidity'])
<Axes: >
```

```

q1=df['citric acid'].quantile(0.25)
q3=df['citric acid'].quantile(0.75)
IQR=q3-q1
IQR
0.32999999999999996

ul=q3+1.5*IQR
ll=q1-1.5*IQR
df['citric acid']=np.where(df['citric acid']>ul,df['citric
acid'].median(),df['citric acid'])

q1=df['residual sugar'].quantile(0.25)
q3=df['residual sugar'].quantile(0.75)
IQR=q3-q1
IQR
0.70000000000000002

ul=q3+1.5*IQR
ll=q1-1.5*IQR
df['residual sugar']=np.where(df['residual sugar']>ul,df['residual
sugar'].median(),df['residual sugar'])
df['residual sugar']=np.where(df['residual sugar']<ll,df['residual
sugar'].median(),df['residual sugar'])
q1=df['pH'].quantile(0.25)

```

```
q3=df['pH'].quantile(0.75)
IQR=q3-q1
IQR
```

0.18999999999999995

```
ul=q3+1.5*IQR
ll=q1-1.5*IQR
df['pH']=np.where(df['pH']>ul,df['pH'].median(),df['pH'])
df['pH']=np.where(df['pH']<ll,df['pH'].median(),df['pH'])
q1=df['sulphates'].quantile(0.25)
q3=df['sulphates'].quantile(0.75)
IQR=q3-q1
IQR
```

0.17999999999999994

```
ul=q3+1.5*IQR
ll=q1-1.5*IQR
df['sulphates']=np.where(df['sulphates']>ul,df['sulphates'].median(),df['sulphates'])
df['sulphates']=np.where(df['sulphates']<ll,df['sulphates'].median(),df['sulphates'])
q1=df['density'].quantile(0.25)
q3=df['density'].quantile(0.75)
IQR=q3-q1
IQR
```


0.0022349999999999987

```
ul=q3+1.5*IQR
ll=q1-1.5*IQR
df['density']=np.where(df['density']>ul,df['density'].median(),df['density'])
df['density']=np.where(df['density']<ll,df['density'].median(),df['density'])
q1=df['quality'].quantile(0.25)
q3=df['quality'].quantile(0.75)
IQR=q3-q1
IQR
```

1.0

```
ul=q3+1.5*IQR
ll=q1-1.5*IQR
df['quality']=np.where(df['quality']>ul,df['quality'].median(),df['quality'])
df['quality']=np.where(df['quality']<ll,df['quality'].median(),df['quality'])
plt.figure(figsize=(20,20))
sns.boxplot(df)
```

<Axes: >



X and Y split

```
x=df.drop(columns=['quality'],axis=1)
y=df.quality
x.head()
```

	fixed acidity	volatile acidity	citric acid	residual sugar
chlorides \				
0	7.4	0.70	0.00	1.9
0.076				

1	7.8	0.88	0.00	2.6
0.098				
2	7.8	0.76	0.04	2.3
0.092				
3	11.2	0.28	0.56	1.9
0.075				
4	7.4	0.70	0.00	1.9
0.076				

	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates
0	11.0	34.0	0.9978	3.51	0.56
1	25.0	67.0	0.9968	3.20	0.68
2	15.0	54.0	0.9970	3.26	0.65
3	17.0	60.0	0.9980	3.16	0.58
4	11.0	34.0	0.9978	3.51	0.56

	alcohol
0	9.4
1	9.8
2	9.8
3	9.8
4	9.4

y.head()

0	5.0
1	5.0
2	5.0
3	6.0
4	5.0

Name: quality, dtype: float64

Scaling Independent Variables

```
from sklearn.preprocessing import MinMaxScaler
scale=MinMaxScaler()
```

```
x_scaled=pd.DataFrame(scale.fit_transform(x),columns=x.columns)
```

x_scaled

	fixed acidity	volatile acidity	citric acid	residual sugar
chlorides \				
0	0.363636	0.651685	0.000000	0.363636
0.448718				

1	0.415584	0.853933	0.000000	0.618182
0.730769				
2	0.415584	0.719101	0.050633	0.509091
0.653846				
3	0.857143	0.179775	0.708861	0.363636
0.435897				
4	0.363636	0.651685	0.000000	0.363636
0.448718				
...
...				
1594	0.207792	0.539326	0.101266	0.400000
0.628205				
1595	0.168831	0.483146	0.126582	0.472727
0.269231				
1596	0.220779	0.438202	0.164557	0.509091
0.448718				
1597	0.168831	0.589888	0.151899	0.400000
0.435897				
1598	0.181818	0.213483	0.594937	0.981818
0.333333				

	free sulfur dioxide	total sulfur dioxide	density	pH	\
0	0.243902	0.241379	0.630058	0.773333	
1	0.585366	0.525862	0.514451	0.360000	
2	0.341463	0.413793	0.537572	0.440000	
3	0.390244	0.465517	0.653179	0.306667	
4	0.243902	0.241379	0.630058	0.773333	
...	
1594	0.756098	0.327586	0.294798	0.693333	
1595	0.926829	0.387931	0.320231	0.786667	
1596	0.682927	0.293103	0.391908	0.653333	
1597	0.756098	0.327586	0.360694	0.853333	
1598	0.414634	0.310345	0.363006	0.613333	

	sulphates	alcohol
0	0.348485	0.196078
1	0.530303	0.274510
2	0.484848	0.274510
3	0.378788	0.274510
4	0.348485	0.196078
...
1594	0.378788	0.411765
1595	0.651515	0.549020
1596	0.636364	0.509804
1597	0.575758	0.352941
1598	0.500000	0.509804

[1599 rows x 11 columns]

```
# Train-test split
```

```
from sklearn.model_selection import train_test_split
x_train,x_test,y_train,y_test=train_test_split(x_scaled,y,test_size=0.
3,random_state=10)
x_train.shape, x_test.shape
```

```
((1119, 11), (480, 11))
```

```
# Machine Learning Model Building
```

```
# Logistic Regression
```

```
from sklearn.linear_model import LogisticRegression
lr=LogisticRegression()
lr.fit(x_train,y_train)
```

```
LogisticRegression()
```

```
y_pred_train=lr.predict(x_train)
y_pred=lr.predict(x_test)
pd.DataFrame({'y_actual':y_test,'y_pred':y_pred})
```

	y_actual	y_pred
1518	5.0	6.0
1246	5.0	5.0
544	6.0	5.0
1343	6.0	6.0
428	5.0	5.0
...
174	5.0	5.0
387	6.0	5.0
1560	5.0	5.0
846	5.0	5.0
1567	5.0	5.0

```
[480 rows x 2 columns]
```

```
# Evaluate the model
```

```
from sklearn.metrics import
accuracy_score,classification_report,confusion_matrix
accuracy_score(y_train,y_pred_train)
accuracy_score(y_test,y_pred)
print(classification_report(y_test,y_pred))
pd.crosstab(y_test,y_pred)
```

	precision	recall	f1-score	support
4.0	0.00	0.00	0.00	16
5.0	0.66	0.67	0.67	210

	6.0	0.52	0.64	0.57	196
	7.0	0.48	0.22	0.31	58
accuracy				0.58	480
macro avg		0.42	0.38	0.39	480
weighted avg		0.56	0.58	0.56	480

```

/usr/local/lib/python3.10/dist-packages/sklearn/metrics/_classification.py:1344: UndefinedMetricWarning: Precision and F-score are ill-defined and being set to 0.0 in labels with no predicted samples. Use `zero_division` parameter to control this behavior.
  _warn_prf(average, modifier, msg_start, len(result))
/usr/local/lib/python3.10/dist-packages/sklearn/metrics/_classification.py:1344: UndefinedMetricWarning: Precision and F-score are ill-defined and being set to 0.0 in labels with no predicted samples. Use `zero_division` parameter to control this behavior.
  _warn_prf(average, modifier, msg_start, len(result))
/usr/local/lib/python3.10/dist-packages/sklearn/metrics/_classification.py:1344: UndefinedMetricWarning: Precision and F-score are ill-defined and being set to 0.0 in labels with no predicted samples. Use `zero_division` parameter to control this behavior.
  _warn_prf(average, modifier, msg_start, len(result))

```

```

col_0    5.0   6.0   7.0
quality
4.0         12    4    0
5.0        140   70    0
6.0         57  125   14
7.0          2   43   13

```

Decision Tree Algorithm

```

from sklearn.tree import DecisionTreeClassifier
dt=DecisionTreeClassifier()
dt.fit(x_train,y_train)
dty_pred=dt.predict(x_test)
dty_pred

```

```

array([7., 5., 6., 6., 6., 6., 7., 5., 6., 6., 7., 7., 5., 5., 6., 4.,
6.,
        6., 6., 5., 5., 6., 6., 5., 5., 6., 5., 6., 6., 5., 5., 5., 6.,
7.,
        5., 5., 7., 5., 6., 5., 6., 6., 5., 6., 5., 7., 6., 7., 6., 5.,
6.,
        7., 6., 7., 5., 5., 7., 5., 5., 6., 5., 6., 7., 7., 5., 6., 6.,
6.,
        6., 5., 6., 5., 6., 6., 5., 5., 6., 7., 5., 6., 7., 5., 7., 5.,
6.,
        6., 5., 5., 6., 5., 7., 7., 7., 6., 5., 6., 5., 5., 6., 6., 7.,

```

```

6.,
5., 6., 6., 6., 5., 6., 6., 5., 5., 6., 7., 5., 5., 5., 5., 6.,
7.,
6., 6., 5., 6., 4., 6., 5., 5., 5., 5., 6., 6., 5., 5., 4., 6.,
7.,
6., 5., 5., 7., 6., 6., 6., 6., 6., 6., 6., 5., 5., 6., 6., 5.,
5.,
7., 6., 6., 5., 4., 5., 7., 7., 7., 7., 5., 5., 4., 6., 7., 7.,
5.,
5., 7., 6., 6., 5., 6., 6., 5., 4., 6., 5., 6., 5., 5., 5., 5.,
4.,
6., 5., 6., 6., 5., 6., 5., 6., 6., 4., 5., 6., 6., 6., 6., 7.,
6.,
5., 5., 5., 5., 6., 7., 5., 6., 6., 5., 7., 6., 6., 5., 5., 6.,
5.,
7., 5., 5., 6., 5., 6., 6., 5., 5., 6., 6., 6., 6., 5., 6., 5.,
6.,
5., 5., 6., 5., 6., 7., 6., 5., 5., 5., 6., 6., 5., 6., 6., 6.,
6.,
6., 7., 7., 6., 6., 5., 5., 7., 5., 5., 4., 4., 7., 7., 6., 5.,
7.,
6., 6., 5., 6., 5., 5., 6., 5., 7., 6., 7., 7., 5., 5., 7., 5.,
4.,
6., 6., 5., 7., 6., 5., 7., 4., 5., 6., 6., 6., 6., 6., 6., 6.,
6.,
6., 6., 6., 5., 6., 5., 6., 6., 6., 6., 7., 7., 5., 6., 6., 6.,
6.,
7., 6., 7., 5., 5., 6., 6., 6., 6., 4., 7., 5., 5., 6., 5., 5.,
5.,
6., 5., 6., 5., 6., 5., 6., 5., 4., 7., 5., 5., 7., 5., 5., 5.,
6.,
5., 6., 6., 5., 6., 7., 5., 5., 5., 6., 5., 5., 6., 6., 5., 5.,
6.,
6., 7., 6., 5., 5., 7., 6., 7., 4., 5., 5., 6., 4., 6., 7., 5.,
6.,
7., 7., 6., 5., 5., 5., 6., 5., 7., 5., 7., 5., 5., 5., 5., 6.,
5.,
6., 6., 6., 5., 6., 5., 5., 6., 5., 6., 6., 7., 5., 4., 5., 5.,
5.,
7., 6., 6., 5., 7., 6., 6., 6., 6., 5., 7., 6., 6., 6., 5., 5.,
6.,
6., 6., 6., 6., 5., 7., 5., 5., 6., 5., 5., 5., 6., 7., 6., 6.,
7.,
5., 6., 5., 6., 7., 6., 6., 7., 6., 6., 6., 4., 5., 5., 5., 5.,
5.,
5.,
5., 6., 5., 5.] )

```

```

# Evaluating Decision Tree Algorithm

```

```

accuracy_score(y_test, dty_pred)

```



```
0.5791666666666667
```

```
print(classification_report(y_test,dt_y_pred))
```

	precision	recall	f1-score	support
4.0	0.06	0.06	0.06	16
5.0	0.70	0.62	0.66	210
6.0	0.58	0.60	0.59	196
7.0	0.41	0.52	0.45	58
accuracy			0.58	480
macro avg	0.44	0.45	0.44	480
weighted avg	0.59	0.58	0.58	480

```
pd.crosstab(y_test,dt_y_pred)
```

```
col_0    4.0    5.0    6.0    7.0
quality
4.0         1     10      4      1
5.0         7    130     62     11
6.0         8     39    117     32
7.0         2      6     20     30
```

```
# Using random tree classifier
```

```
from sklearn.ensemble import RandomForestClassifier
```

```
rf=RandomForestClassifier()
```

```
rf.fit(x_train,y_train)
```

```
rfy_pred=rf.predict(x_test)
```

```
rfy_pred
```

```
array([6., 5., 6., 6., 6., 6., 6., 6., 6., 5., 7., 6., 5., 5., 6., 5.,
5.,
      6., 6., 5., 5., 6., 6., 5., 5., 6., 5., 6., 6., 5., 5., 5., 6.,
7.,
      5., 5., 7., 5., 6., 5., 6., 6., 5., 6., 5., 6., 6., 7., 6., 6.,
6.,
      7., 6., 7., 6., 6., 6., 5., 5., 5., 6., 5., 7., 6., 5., 6., 6.,
6.,
      5., 7., 5., 5., 5., 5., 6., 5., 5., 7., 5., 6., 7., 5., 6., 5.,
6.,
      6., 5., 5., 6., 5., 7., 6., 7., 6., 5., 6., 5., 5., 6., 6., 7.,
5.,
      5., 6., 6., 5., 5., 6., 6., 5., 5., 6., 7., 5., 5., 5., 5., 5.,
6.,
```

```

6., 6., 5., 5., 6., 5., 5., 5., 5., 5., 5., 6., 6., 5., 6., 5., 6.,
6., 6., 5., 5., 7., 6., 6., 5., 6., 6., 6., 5., 5., 6., 6., 5., 7.,
6., 7., 6., 6., 5., 5., 6., 6., 6., 6., 7., 5., 5., 6., 6., 7., 6.,
5., 5., 7., 6., 6., 5., 6., 5., 5., 5., 6., 6., 6., 6., 6., 5., 5.,
5., 6., 5., 5., 5., 5., 6., 6., 6., 6., 5., 5., 7., 6., 6., 6., 6.,
6., 5., 6., 5., 5., 5., 7., 6., 6., 6., 5., 5., 6., 6., 5., 5., 5.,
5., 6., 5., 6., 7., 5., 6., 5., 5., 5., 5., 6., 6., 5., 5., 6., 5.,
5., 5., 6., 5., 5., 6., 6., 5., 5., 5., 5., 6., 5., 6., 5., 5.,
6., 6., 7., 7., 7., 6., 5., 5., 6., 5., 5., 5., 5., 6., 6., 6., 5.,
7., 6., 6., 5., 5., 5., 5., 6., 5., 6., 6., 6., 7., 4., 5., 6., 6.,
5., 6., 6., 5., 6., 6., 5., 7., 5., 6., 5., 6., 6., 6., 6., 6., 6.,
6., 5., 7., 6., 5., 6., 5., 6., 6., 6., 6., 7., 7., 5., 5., 6., 6.,
6., 7., 5., 6., 5., 5., 5., 5., 5., 7., 6., 6., 5., 5., 5., 5., 5.,
5., 6., 5., 6., 6., 6., 5., 6., 5., 5., 6., 5., 5., 7., 5., 5., 5.,
6., 5., 6., 5., 5., 6., 6., 5., 5., 5., 6., 5., 5., 6., 5., 5., 5.,
6., 6., 7., 6., 5., 5., 7., 6., 5., 6., 5., 5., 5., 5., 6., 6., 5.,
6., 6., 7., 6., 5., 5., 6., 6., 5., 6., 5., 6., 5., 5., 5., 5., 6.,
6., 6., 7., 6., 5., 6., 5., 5., 5., 5., 6., 6., 6., 5., 5., 6., 5.,
5., 6., 5., 6., 5., 7., 6., 6., 6., 6., 5., 6., 6., 6., 6., 5., 5.,
6., 6., 6., 6., 5., 7., 5., 6., 6., 5., 6., 5., 5., 6., 5., 6.,
6., 5., 6., 5., 6., 7., 6., 6., 7., 6., 7., 5., 5., 5., 5., 6., 5.,
5., 5., 5., 5., 5.]])

```

```

rfy_pred_train=rf.predict(x_train)
# Evaluation for random tree classifier
accuracy_score(y_train,rfy_pred_train)

```

```
1.0
```

```
accuracy_score(y_test,rfy_pred)
```

```
0.68125
```

```
accuracy_score(y_test,rfy_pred)
```

```
0.68125
```

```
pd.crosstab(y_test,rfy_pred)
```

col_0	4.0	5.0	6.0	7.0
quality				
4.0	0	11	5	0
5.0	0	163	45	2
6.0	1	45	136	14
7.0	0	2	28	28

```
print(classification_report(y_test,rfy_pred))
```

	precision	recall	f1-score	support
4.0	0.00	0.00	0.00	16
5.0	0.74	0.78	0.76	210
6.0	0.64	0.69	0.66	196
7.0	0.64	0.48	0.55	58
accuracy			0.68	480
macro avg	0.50	0.49	0.49	480
weighted avg	0.66	0.68	0.67	480

```
# Test with random observation
```

```
rf.predict([[7.4,0.28,0.04,2.6,0.076,25,38,0.9978,3.51,0.67,9.4]])
```

```
/usr/local/lib/python3.10/dist-packages/sklearn/base.py:439:
```

```
UserWarning: X does not have valid feature names, but
```

```
RandomForestClassifier was fitted with feature names
```

```
warnings.warn(
```

```
array([5.]
```